Αναφορά Εργαστηριακής Άσκησης

Συστήματα Διαχείρισης Δεδομένων Μεγάλου Όγκου

Εργαστηριακή Άσκηση 2023/24

Όνομα	**Επώνυμο**	**ΑΜ**
Δημήτριος	Στασινός	1084643
Βασίλειος-Μάριος	Κουρτάκης	1090061

Βεβαιώνω ότι είμαι συγγραφέας της παρούσας εργασίας και ότι έχω αναφέρει ή παραπέμψει σε αυτήν, ρητά και συγκεκριμένα, όλες τις πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών, προτάσεων ή λέξεων, είτε αυτές μεταφέρονται επακριβώς (στο πρωτότυπο ή μεταφρασμένες) είτε παραφρασμένες. Επίσης βεβαιώνω ότι αυτή η εργασία προετοιμάστηκε από εμένα προσωπικά ειδικά για το συγκεκριμένο μάθημα/σεμινάριο/πρόγραμμα σπουδών.

Έχω ενημερωθεί ότι σύμφωνα με τον εσωτερικό κανονισμό λειτουργίας του Πανεπιστημίου Πατρών άρθρο 50§6, τυχόν προσπάθεια αντιγραφής ή εν γένει φαλκίδευσης της εξεταστικής και εκπαιδευτικής διαδικασίας από οιονδήποτε εξεταζόμενο, πέραν του μηδενισμού, συνιστά βαρύ πειθαρχικό παράπτωμα.

Υπογραφή

21 / 6 / 2024

Υπογραφή

21 /6 / 2024

Συνημμένα αρχεία κώδικα

Μαζί με την παρούσα αναφορά υποβάλλουμε τα παρακάτω αρχεία κώδικα

Αρχείο	Αφορά το ερώτημα	Περιγραφή/Σχόλιο
kafkaProducer.py	*Ερώτημα 1*	*Περιέχει τα ερωτήματα 1.1, 1.4*
kafkaConsumer.py	*Ερώτημα 1*	*Περιέχει το ερώτημα 1.5*
spark.py	*Ερώτημα 2*	*Περιέχει το ερώτημα 2.2*
mongodbQuery.py	*Ερώτημα 3*	*Περιέχει το ερώτημα 3.1, 3.2, 3.3 (το python script με τα queries στη MongoDB)*

Τεχνικά χαρακτηριστικά περιβάλλοντος λειτουργίας

Χαρακτηριστικό	**Τιμή**
CPU model	*AMD Ryzen 5 Mobile 4600H*
CPU clock speed	*3.0 GHz*
Physical CPU cores	*6*
Logical CPU cores	*12*
RAM	*16 GB*
Secondary Storage Type	*SSD*

Ερώτημα 1: Παραγωγή δεδομένων

Για τη δημιουργία των δεδομένων χρησιμοποιούμε τον εξομοιωτή UXSIM και τον κώδικα που παρέχεται. Το simulation μας έχει tmax=600, δηλαδή διάρκεια 10 λεπτών και τα αποτελέσματα που παρέχονται τα τοποθετούμε σε Dataframe. Επίσης παρατηρούμε ότι κάθε ακμή έχει μέγεθος 500 μέτρα και όριο ταχύτητας 30χμλ και 50χμλ για τους παράδρομους και τον κεντρικό δρόμο αντίστοιχα. Έπειτα, δημιουργούμε έναν Kafka producer ο οποίος συνδέεται με τον Kafka cluster που έχουμε δημιουργήσει. Επιπλέον παίρνουμε δύο datetime, ένα για την αρχή της εξομοίωσης (sim_start) και ένα που δείχνει πότε ο producer ξεκίνησε την αποστολή δεδομένων (start_time).

Με την συνάρτηση “sim_time_send” στέλνουμε αρχικά πότε ξεκίνησε η παραγωγή των δεδομένων για να την χρησιμοποιήσουμε στην spark. Μετά με την συνάρτηση “data_to_kafka” στέλνουμε τα δεδομένα στο kafka broker. Σε αυτή την συνάρτηση ελέγχουμε την μέγιστη τιμή της στήλης time και όσο η μεταβλητή i (αρχικά i=0) δεν την έχει φτάσει, στέλνουμε τις στήλες όπου time=i. Ο simulator συλλέγει τα δεδομένα ανά 5 seconds ως αποτέλεσμα αυξάνουμε το i κατά 5. Επιπλέον σε αυτή την συνάρτηση αφαιρούμε την στήλη dn όπως φαίνεται στο παράδειγμα της εκφώνησης, μετατρέπουμε τα δεδομένα σε JSON και προσθέτουμε σε κάθε γραμμή το datetime έναρξης του producer με την μεταβλητή που περιέχεται στη στήλη time όπως ζητείται. Αγνοούμε τις γραμμές όπου το όχημα δεν έχει ξεκινήσει καθώς και αυτές που έχει τερματίσει την διαδρομή του (δηλαδή τις γραμμές όπου link= “Waiting_at_origin_node” ή “trip_end”). Η αποστολή των δεδομένων στον kafka broker γίνεται ανά 4 δευτερόλεπτα με κάθε θέση οχήματος να είναι ξεχωριστό JSON αντικείμενο.

Network

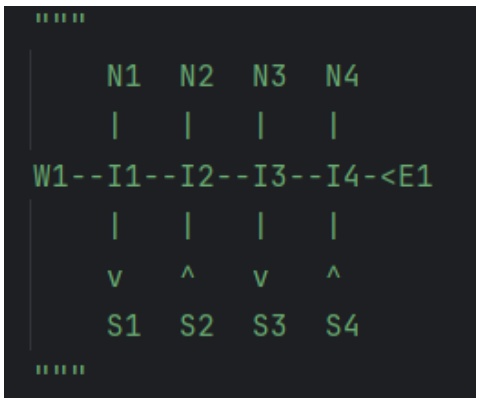

Παράμετροι

```
W = World(
    name="",
    deltan=5,
    tmax=600,  # 1 hour simulation
    print_mode=1, save_mode=0, show_mode=1,
    random_seed=seed,
    duo_update_time=600
)
```

Εκτέλεση Kafka:

Ακολουθούμε τον οδηγό που μας παρέχεται «Οδηγίες εγκατάστασης Kafka» εκτελώντας τις εντολές που μας παρέχει. Πρώτα κατεβάζουμε τον kafka 3.7.0 με scala 2.13. Για να ξεκινήσουμε τον kafka server και να δημιουργήσουμε το topic vehicle_positions τρέχουμε τις εντολές:

1) bin/zookeeper-server-start.sh config/zookeeper.properties:

2) bin/kafka-server-start.sh -daemon config/server.properties:

3) bin/kafka-topics.sh --create --topic vehicle_positions --bootstrap-server localhost:9092:

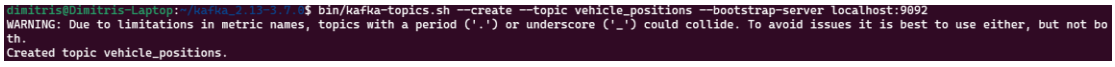

Για την γρήγορη έναρξη του kafka broker έχουμε φτιάξει ένα αρχείο .sh που επιταχύνει αυτή την διαδικασία:

```
#!/bin/bash
echo "Starting Zookeeper..."
bin/zookeeper-server-start.sh -daemon config/zookeeper.properties
sleep 3
echo "Starting Kafka..."
bin/kafka-server-start.sh -daemon config/server.properties
sleep 3
echo "Create Topic vehicle_positions..."
bin/kafka-topics.sh --create --topic vehicle_positions --bootstrap-server localhost:9092
sleep 3
echo "List of Topics"
bin/kafka-topics.sh --list --bootstrap-server localhost:9092
echo "Ready"
```

```
dimitris@Dimitris-Laptop:~/kafka_2.13-3.7.0$ ./startKafka.sh
Starting Zookeeper...
Starting Kafka...
Create Topic vehicle_positions...
WARNING: Due to limitations in metric names, topics with a period ('.') or underscore ('_') could collide. To avoid issues it is best to use either, but not bo
th.
Created topic vehicle_positions.
List of Topics
vehicle_positions
Ready
```

Από το παραπάνω script, φαίνεται πως δημιουργούμε το topic με όνομα vehicle_positions.

Λειτουργία μοντέλου consumer-producer

Producer

```
/home/dimitris/big_data/venv/bin/python /home/dimitris/big_data/kafkaProducer.py
simulation setting:
 scenario name:
 simulation duration:    600 s
 number of vehicles:     15105 veh
 total road length:  6500 m
 time discret. width:    5 s
 platoon size:       5 veh
 number of timesteps:    120
 number of platoons:     3021
 number of links:    13
 number of nodes:    14
 setup time:         0.46 s
simulating...
      time| # of vehicles| ave speed| computation time
       0 s|        0 vehs|   0.0 m/s|     0.00 s
     595 s|      580 vehs|   2.5 m/s|     0.52 s
 simulation finished
```

Consumer

```
/home/dimitris/big_data/venv/bin/python /home/dimitris/big_data/kafkaConsumer.py
Received message: {'name': 'null', 'origin': 'null', 'destination': 'null', 'time': '20/06/2024 21:35:07', 'link': 'null', 'position': 'null', 'spacing': 'null', 'speed': 'null'}
Received message: {'name': '8', 'origin': 'E1', 'destination': 'W1', 'time': '20/06/2024 21:35:13', 'link': 'E1I4', 'position': 0.0, 'spacing': -1.0, 'speed': 50.0}
Received message: {'name': '15', 'origin': 'N1', 'destination': 'W1', 'time': '20/06/2024 21:35:13', 'link': 'N1I1', 'position': 0.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '22', 'origin': 'S2', 'destination': 'W1', 'time': '20/06/2024 21:35:13', 'link': 'S2I2', 'position': 0.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '29', 'origin': 'N3', 'destination': 'W1', 'time': '20/06/2024 21:35:13', 'link': 'N3I3', 'position': 0.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '36', 'origin': 'S4', 'destination': 'W1', 'time': '20/06/2024 21:35:13', 'link': 'S4I4', 'position': 0.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '8', 'origin': 'E1', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'E1I4', 'position': 250.0, 'spacing': -1.0, 'speed': 50.0}
Received message: {'name': '9', 'origin': 'E1', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'E1I4', 'position': 0.0, 'spacing': -1.0, 'speed': 50.0}
Received message: {'name': '15', 'origin': 'N1', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'N1I1', 'position': 150.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '16', 'origin': 'N1', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'N1I1', 'position': 0.0, 'spacing': 300.0, 'speed': 30.0}
Received message: {'name': '22', 'origin': 'S2', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'S2I2', 'position': 150.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '23', 'origin': 'S2', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'S2I2', 'position': 0.0, 'spacing': 300.0, 'speed': 30.0}
Received message: {'name': '29', 'origin': 'N3', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'N3I3', 'position': 150.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '30', 'origin': 'N3', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'N3I3', 'position': 0.0, 'spacing': 300.0, 'speed': 30.0}
Received message: {'name': '36', 'origin': 'S4', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'S4I4', 'position': 150.0, 'spacing': -1.0, 'speed': 30.0}
Received message: {'name': '37', 'origin': 'S4', 'destination': 'W1', 'time': '20/06/2024 21:35:18', 'link': 'S4I4', 'position': 0.0, 'spacing': 300.0, 'speed': 30.0}
```

Ερώτημα 2: Κατανάλωση και επεξεργασία με Spark

Αρχικά, αρχικοποιούμε τις μεταβλητές simulation_start, date_check, start_time_tmp τις οποίες χρησιμοποιούμε για να βρούμε την αρχή της εξομοίωσης, τον έλεγχο αν βρήκαμε το timestamp που έχουμε θέσει ως αρχή της εξομοίωσης και τη λίστα που αποθηκεύει αυτή τη τιμή αντίστοιχα. Έπειτα, φτιάχνουμε το schema , το οποίο χρησιμοποιούμε για να ορίσουμε σαν αρχικό Column στο Dataframe που δεχόμαστε από τον Kafka.

Φτιάχνουμε το sparkSession (αν δεν υπάρχει ήδη, το δημιουργούμε) και συνδεόμαστε στο stream του Kafka Server, για να διαβάσουμε τα δεδομένα. Μετά, χειριζόμαστε τα δεδομένα σε Batches(“.forEachBatch(process_data_send_db)”), χρησιμοποιούμε τα triggers για να σιγουρευτούμε ότι λαμβάνουμε σωστά τα δεδομένα και κάνουμε τις ανάλογες τροποποιήσεις μέσα στην process_data_send_db.

Μέσα στην συνάρτηση process_data_send_db, χρησιμοποιώντας το Dataframe API, κάνουμε selectExpr και Cast κάθε value σε String από το JSON που λαμβάνουμε, τροποποιούμε το Column του time, μετατρέποντάς το σε timestamp και όλα αυτά τα δεδομένα επιστρέφονται ως Dataframe. Για να μπορέσουμε να διαχειριστούμε τη πρώτη τιμή που λαμβάνουμε, το οποίο είναι η αρχή της εξομοίωσης, θέτουμε ένα καινούργιο column, το οποίο το έχουμε αποκλειστικά για να θέσουμε τη τιμή της αρχής της εξομοίωσης (αρχικά είναι "00/00/00 00:00:00"). Όταν λάβουμε από τον Kafka αυτή τη τιμή μέσω του .where(''' name=='null' ''') το οποίο επιστρέφει αποτέλεσμα μόνο αν η στήλη name έχει τη τιμή του string 'null' , (ισχύει μόνο στη συγκεκριμένη περίπτωση) και έπειτα με τη χρήση του collect() το συλλέγει και το αποθηκεύει σαν λίστα. Το if υπάρχει καθώς δε θέλουμε να κάνουμε αχρείαστα queries στο Dataframe.

Για να σιγουρευτούμε ότι υπάρχουν αντικείμενα στη λίστα αυτή, ελέγχουμε πρώτα αν είναι κενή και αν έχουμε λάβει επιτυχώς αυτή τη τιμή με τη Boolean date_check. Αποθηκεύουμε το value και δε το στέλνουμε. Έπειτα, αφότου λάβαμε επιτυχώς αυτή τη τιμή, στέλνουμε σαν batches τα ωμά δεδομένα στη συλλογή "Cars_raw" της βάσης "Big_Data_Project". Τα ωμά δεδομένα περιέχουν το timestamp, χωρίς κάποια επιπλέον επεξεργασία. Όμως, στα επεξεργασμένα δεδομένα, αλλάζουμε τη στήλη time στην οποία αφαιρούμε το timestamp που περιέχει με αυτό της αρχής της εξομοίωσης και το αποτέλεσμα που βρίσκουμε είναι σε seconds το οποίο είναι η χρονική στιγμή από την αρχή της εξομοίωσης. Για να στείλουμε σωστά τα δεδομένα, στη μεταβλητή processed_dataframe, διαλέγουμε μόνο τα columns που μας ενδιαφέρουν και κάνουμε groupby με τα link, time και έπειτα βρίσκουμε το πλήθος των οχημάτων που περνάνε μέσα από ένα link καθώς και τη μέση ταχύτητα των οχημάτων αυτών. Τέλος, προσθέτουμε συνεχώς batches δεδομένων στη MongoDB τα δεδομένα της processed_dataframe στη συλλογή "Cars_processed" της βάσης "Big_Data_Project" στον local MongoDB server μας. Αν δεν υπάρχουν η συλλογή και η βάση, δημιουργούνται μόνες τους. Ακολουθούν screenshot εκτέλεσης και τα ερωτήματα επεξεργασίας των Dataframe.

Screenshots εκτέλεσης spark:

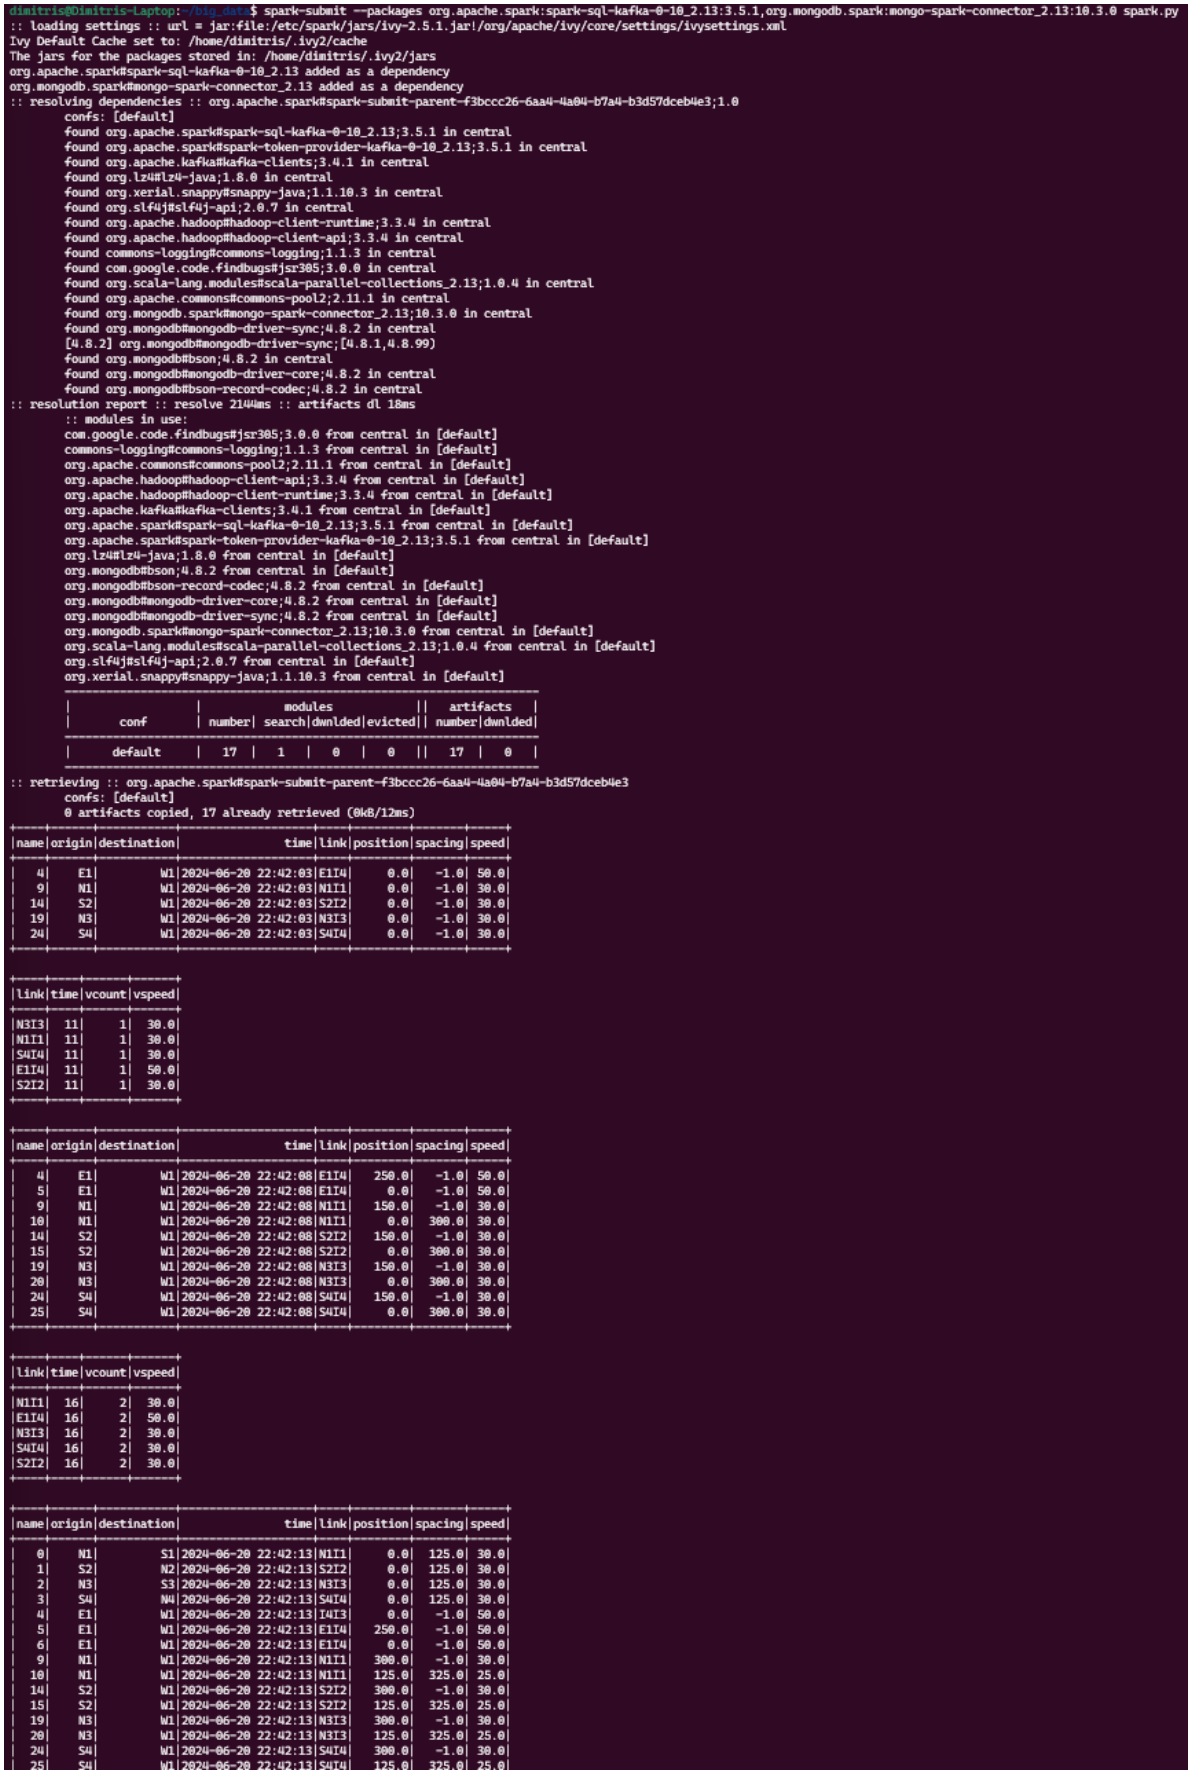

Ωμά δεδομένα σε Dataframe:

```
data_dataframe_raw = data.selectExpr("CAST(value AS STRING)") \
    .select(from_json(col:"value", schema).alias("data")) \
    .select("data.*") \
    .withColumn("time", to_timestamp("time", "dd/MM/yyyy HH:mm:ss"))  # Transform column value of time to timestamp
```

Χειρισμός επεξεργασμένων δεδομένων:

```
# Change time column to t , where t the difference between simulation start and current timestamp of time
data_dataframe = data_dataframe.withColumn("time", (unix_timestamp(col("time")) -
                                                    unix_timestamp(
                                                        "simulation_start")))

# Query only asked values (time,link,speed) and create columns with count of link for grouped by link,
# time and avg of speed
processed_dataframe = data_dataframe.selectExpr("time", "link", "speed") \
    .groupby("link","time") \
    .agg(count("link").alias("vcount"),
         avg("speed").alias(
             "vspeed"))
```

Προσθήκη simulation_start:

```
data_dataframe = data_dataframe_raw.withColumn("simulation_start",
                                               lit(simulation_start))
```

Το οποίο παίρνει την τιμή της αρχής της εξομοίωσης, αφότου τη λάβουμε, όπως αναφέρεται παραπάνω.

Εγκατάσταση του Spark:

Αρχικά κατεβάσαμε την έκδοση 3.5.1 της spark (spark-3.5.1-bin-hadoop3-scala2.13.tgz) με Scala 2.13. Ακολουθώντας τον οδηγό που μας παρέχεται (Κατανάλωση δεδομένων από Kafka και επεξεργασία JSON σε Spark) εγκαθιστούμε την έκδοση του spark και τρέχουμε τον spark μαζί με τα packages της Kafka και του MongoDB-Spark connector με την εντολή:

```
dimitris@Dimitris-Laptop:~/big_data$ spark-submit --packages org.apache.spark:spark-sql-kafka-0-10_2.13:3.5.1,org.mongodb.spark:mongo-spark-connector_2.13:10.3.0 spark.py
```

Ερώτημα 3: Αποθήκευση σε MongoDB

Η βάση δεδομένων αποτελείται από το Database Big_Data_Project και δύο Collection, το Cars_processed που περιέχει τα επεξεργασμένα δεδομένα και το Cars_raw που περιέχει τα ωμά δεδομένα.

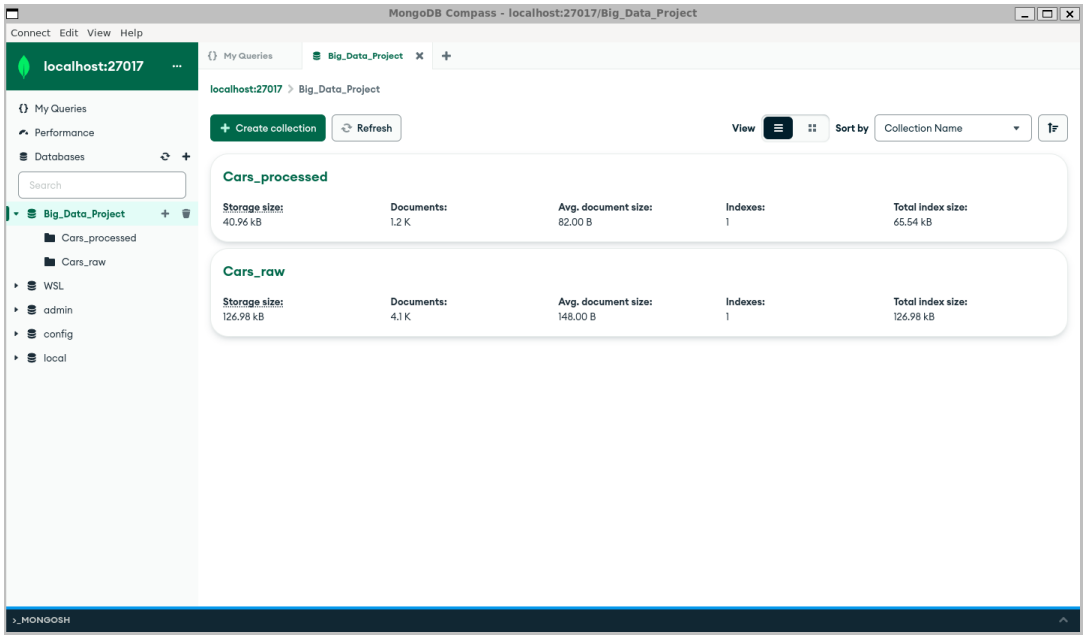

Την Database και τα Collection φτιάχνονται από την εκτέλεση του spark .Εάν δεν υπάρχουν, τα φτιάχνουμε μέσω του mongodb-compass(το GUI που παρουσιάζεται στο παραπάνω screenshot). Δημιουργία μέσω spark:

Ωμά δεδομένα

```
# Send raw_data to collection Cars_raw of Big_Data_Project at our local MongoDB database (create database an
# collection, if they don't exist)
1 usage
def raw_data_db_send(raw_dataframe):
    raw_dataframe.write \
        .mode("append") \
        .format("mongodb") \
        .option("spark.mongodb.output.uri", "mongodb://localhost:27017/") \
        .option("spark.mongodb.database", "Big_Data_Project") \
        .option("spark.mongodb.collection", "Cars_raw") \
        .save()
```

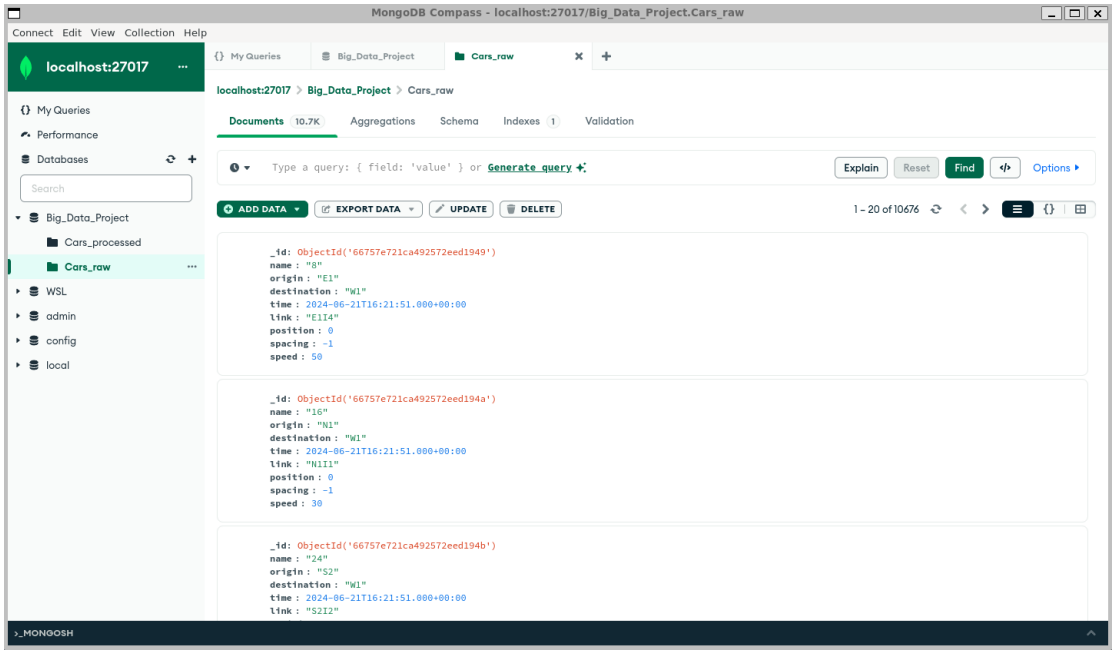

Εδώ αποθηκεύουμε τα ωμά δεδομένα στο Collection Cars_raw της Mongodb της βάσης δεδομένων Big_Data_Project σε append mode και format mongodb.

Επεξεργασμένα δεδομένα

```
# Send values to collection Cars_processed of Big_Data_Project at our local MongoDB database (create database
# and collection, if they don't exist)
processed_dataframe.write \
    .format("mongodb") \
    .mode("append") \
    .option("spark.mongodb.output.uri", "mongodb://localhost:27017/") \
    .option("spark.mongodb.database", "Big_Data_Project") \
    .option("spark.mongodb.collection", "Cars_processed") \
    .save()
```

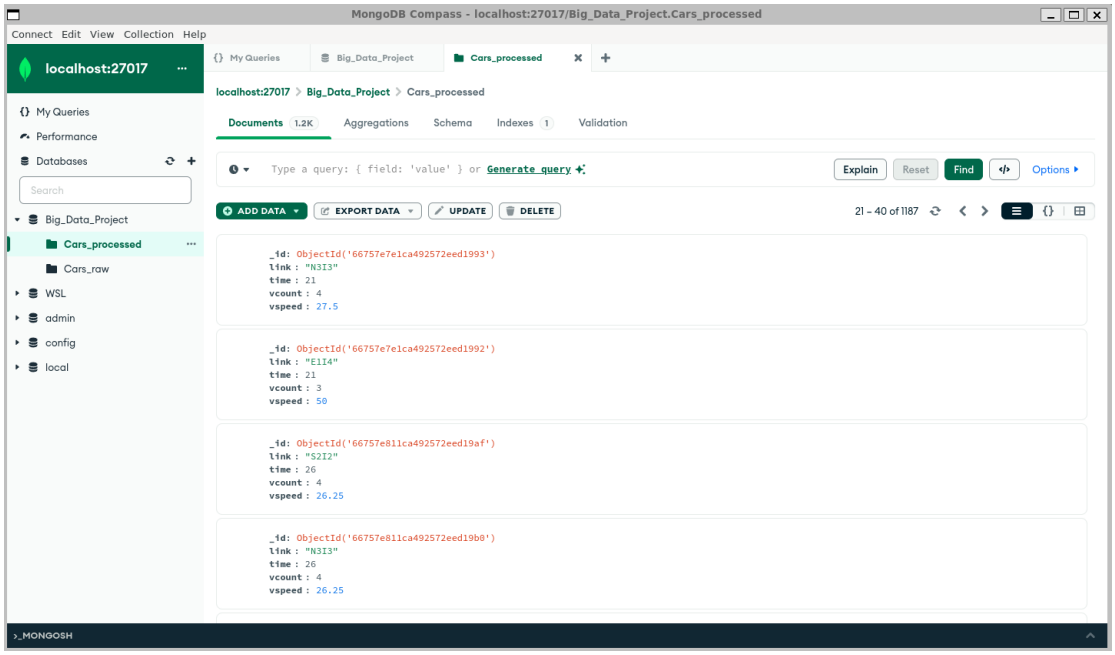

Αποθηκεύουμε τα επεξεργασμένα δεδομένα στο Collection Car_processed της Mongodb της βάσης δεδομένων Big_Data_Project σε append mode και format mongodb

Για την εκτέλεση των queries στην MongoDB χρησιμοποιούμε το script mongodbQuery.py χρησιμοποιώντας aggregation pipelines. Το πρώτο query βρίσκουμε την ακμή με το μικρότερο πλήθος οχημάτων μεταξύ μιας προκαθορισμένης χρονικής περιόδου μέσο της συνάρτησης min_vcount χρησιμοποιώντας το Collection Cars_processed. Αρχικά παίρνουμε τα documents που βρίσκονται στο χρονικό διάστημα που εισάγουμε (match), τα κάνουμε groupby με το link και παίρνουμε το άθροισμα του vcount για κάθε link. Έπειτα βρίσκουμε το μικρότερο άθροισμα vcount και κάνουμε lookup στο ίδιο Collection ακολουθώντας την ίδια διαδικασία για να βρούμε το άθροισμα vcount για κάθε link. Τέλος για κάθε link παίρνουμε τα αποτελέσματα που έχουν το ελάχιστο vcount που έχουμε βρει αρχικά.

```
The link with the smallest number of vehicles between 200 sec and 500 sec was I3S3 with 15 vehicle(s)
```

Για το δεύτερο query, για να βρούμε την ακμή με την μεγαλύτερη μέση ταχύτητα χρησιμοποιούμε το Collection Cars_raw. Σε αυτό πρώτα βρίσκουμε τα document που είναι μέσα στο χρονικό διάστημα που θέλουμε, τα κάνουμε groupby το link βρίσκοντας το μέσο όρο της ταχύτητας κάθε link. Έπειτα βρίσκουμε τον μεγαλύτερο μέσο όρο και κάνουμε lookup στο ίδιο Collection ώστε να βρούμε με τον ίδιο τρόπο το μέσο όρο κάθε ακμής και να πάρουμε αυτά που έχουν ίδια με το μέγιστο που έχουμε ήδη βρει.

```
The link with the highest average speed between 2024-06-21 16:22:00 sec and 2024-06-21 16:24:05 sec was I1W1 with avgSpeed 33.439153466905864
```

Για το τελευταίο query χρησιμοποιούμε το Collection Cars_raw. Μέσα από αυτό βρίσκουμε ποιο όχημα έχει διανύσει την μεγαλύτερη διαδρομή μέσα στο χρονικό διάστημα που δίνουμε. Αρχικά παίρνουμε τα documents που βρίσκονται μέσα στο χρονικό διάστημα που θέλουμε, τα κάνουμε group by το όνομα κάθε οχήματος τοποθετούμε σε ένα array τα μοναδικά link που έχει περάσει ($addToSet) και όλες τις τοποθεσίες του ($push) σε ένα δεύτερο array. Έπειτα βρίσκουμε το μέγεθος και των δύο arrays για κάθε link. Με την $addFields υπολογίζουμε την απόσταση που έχει διανύσει ελέγχοντας εάν έχει διανύσει 1 ή παραπάνω links. Εάν έχει διανύσει ένα τότε ελέγχουμε πόσες τοποθεσίες έχουμε για αυτό το όχημα, αν είναι μια έχει διανύσει 0 μέτρα ενώ εάν έχουμε παραπάνω αφαιρούμε από την τελική την αρχική απόσταση. Μετά εάν έχει περάσει παραπάνω links προσθέτουμε 500 μέτρα (κάθε ακμή έχει μέγεθος 500 μέτρα) για κάθε ένα από ενδιάμεσα links και για το link που ξεκίνησε αφαιρούμε 500 μείον την αρχική θέση του στο link. Για το τελευταίο link που βρίσκονταν απλά βρίσκουμε την τελική του θέση και τελικά προσθέτουμε και τα τρία αποτελέσματα βρίσκοντας την συνολική απόσταση που έχει διανύσει το όχημα. Τέλος βρίσκουμε την μεγαλύτερη απόσταση και παίρνουμε τα links που έχουν διανύσει απόσταση ίση με αυτή.

```
The car with the biggest route distance between 2024-06-21 16:22:00 and 2024-06-21 16:24:05 was 11 with 2433.3333435058594
```

Αποτελέσματα

```
/home/dimitris/big_data/venv/bin/python /home/dimitris/big_data/mongodbQuery.py
The link with the smallest number of vehicles between 200 sec and 500 sec was I3S3 with 15 vehicle(s)
The link with the highest average speed between 2024-06-21 16:22:00 sec and 2024-06-21 16:24:05 sec was I1W1 with avgSpeed 33.439153466905864
The car with the biggest route distance between 2024-06-21 16:22:00 and 2024-06-21 16:24:05 was 11 with 2433.3333435058594
```

Πρώτο Query

```
# Query
pipeline = [
    {
        "$match": {
            "time": {"$gte": time_from, "$lte": time_to}
        }
    },
    {
        "$group": {
            "_id": "$link",
            "sumCount": {"$sum": "$vcount"}
        }
    },
    {
        "$group": {
            "_id": None,
            "minCount": {"$min": "$sumCount"}
        }
    },
    {
        "$lookup": {
            "from": "Cars_processed",
            "let": {"minCount": "$minCount"},
            "pipeline": [
                {
                    "$match": {
                        "time": {"$gte": time_from, "$lte": time_to}
                    }
                },
                {
                    "$group": {
                        "_id": "$link",
                        "sumCount": {"$sum": "$vcount"}
                    }
                },
                {
                    "$match": {
                        '$expr': {"$eq": ["$sumCount", "$$minCount"]}
                    }
                }
            ],
            "as": "result"
        }
    },
    {
        '$unwind': '$result'
    },
    {
        '$replaceRoot': {
            'newRoot': '$result'
        }
    }

]
```

Δεύτερο Query

```
# Query
pipeline = [
    {
        "$match": {
            "time": {"$gte": date_from, "$lte": date_to}
        }
    },
    {
        "$group": {
            "_id": "$link",
            "avgSpeed": {"$avg": "$speed"}
        }
    },
    {
        "$group": {
            "_id": None,
            "maxSpeed": {"$max": "$avgSpeed"}
        }
    },
    {
        "$lookup": {
            "from": "Cars_raw",
            "let": {"maxSpeed": "$maxSpeed"},
            "pipeline": [
                {
                    "$match": {
                        "time": {"$gte": date_from, "$lte": date_to}
                    }
                },
                {
                    "$group": {
                        "_id": "$link",
                        "avgSpeed": {"$avg": "$speed"}
                    }
                },
                {
                    "$match": {
                        '$expr': {"$eq": ["$avgSpeed", "$$maxSpeed"]}
                    }
                }
            ],
            "as": "result"
        }
    },
    {
        '$unwind': '$result'
    },
    {
        '$replaceRoot': {
            'newRoot': '$result'
        }
    }
]
```

Τρίτο Query

```
# Query
pipeline = [
    {
        "$match": {
            "time": {"$gte": date_from, "$lte": date_to}
        }
    },
    {
        "$group": {
            "_id": "$name",
            "link": {"$addToSet": "$link"},
            "position": {"$push": "$position"},
        }
    },
    {
        "$addFields": {
            "link_size": {"$size": "$link"},
            "pos_size": {"$size": "$position"}
        }
    },
    {
        "$addFields": {
            "route_distance": {
                "$cond": {
                    "if": {"$eq": ["$link_size", 1]},
                    "then": {
                        "$cond": {
                            "if": {"$eq": ["$pos_size", 1]},
                            "then": 0,
                            "else": {
                                "$subtract": [{"$arrayElemAt": ["$position", -1]},
                                              {"$arrayElemAt": ["$position", 0]}]
                            }
                        }
                    },
                    "else": {
                        "$add": [
                            {"$subtract": [500, {"$arrayElemAt": ["$position", 0]}]},
                            {"$multiply": [{"$subtract": ["$link_size", 2]}, 500]},
                            {"$arrayElemAt": ["$position", -1]}
                        ]
                    }
                }
            }
        }
    },
    {
        "$project": {
            "_id": 0,
            "name": "$_id",
            "route_distance": 1
        }
    },
    {
        "$group": {
            "_id": None,
            "max_distance": {"$max": "$route_distance"},
            "route_car": {"$push": {"name": "$name", "route_distance": "$route_distance"}}
        }
    },
    {"$unwind": "$route_car"},
    {
        "$match": {
            "$expr": {"$eq": ["$max_distance", "$route_car.route_distance"]}
        }
    },
    {
        "$project": {
            "_id": 0,
            "name": "$route_car.name",
            "route_distance": "$route_car.route_distance"
        }
    }
]
```

Εγκατάσταση MongoDB

Για να εγκαταστήσουμε σωστά τη MongoDB ακολουθήσαμε τις οδηγίες που παρέχονται από την ιστοσελίδα της MongoDB:
https://www.mongodb.com/docs/manual/tutorial/install-mongodb-on-ubuntu/

Εγκαθιστούμε την έκδοση 7.0.11 της MongoDB.

Η έκδοση Ubuntu (WSL2) που έχουμε είναι 22.04 και το init system μας είναι το systemd.

Το GUI που χρησιμοποιούμε είναι το mongodb-compass , το οποίο το εγκαθιστούμε με την βοήθεια των οδηγιών που παρέχονται από τον ιστότοπο:

https://www.mongodb.com/docs/compass/current/install/

Απαραίτητο να αναφερθεί, και πάλι, πως και στα packages του kafka προσθέτουμε τον mongo-spark-connector έκδοσης 10.3.0.

Σχολιασμός αποτελεσμάτων

Από αυτό το project, κατανοήσαμε την σημασία ύπαρξης των Kafka servers, σε συνδυασμό με τη διαχείριση εισερχομένων δεδομένων μέσω της Spark και αποθήκευση των δεδομένων σε ένα NoSQL σύστημα όπως είναι η MongoDB.

Πιο συγκεκριμένα, τα δεδομένα που παράγονται από την εξομοίωση της UXSIM μπορούμε με ευκολία να τα στείλουμε με τη χρήση του Kafka Server. Έπειτα, διαχειριζόμαστε τα δεδομένα που έχουμε στείλει, από τον Kafka, με τη χρήση της Spark. Η Spark είναι πολύ χρήσιμη στη περίπτωσή μας, καθώς είναι αναγκαίο να διαχειριστούμε μεγάλο όγκο δεδομένων με μεγάλη ταχύτητα. Τέλος, τα δεδομένα στέλνουμε σε μία βάση δεδομένων, τη MongoDB, η οποία αποθηκεύει σε batches τα δεδομένα τα οποία διαχειριστήκαμε όσο και τα ωμά.

Έτσι, δημιουργήσαμε ένα πλήρως λειτουργικό σύστημα διαχείρισης πραγματικών δεδομένων (DSMS, Data Streaming Management System) και κατανοήσαμε την αξία ύπαρξής του, σε περιβάλλοντα ανάκτησης μεγάλου πλήθους δεδομένων στο πραγματικό κόσμο καθώς και real-time δεδομένων.

Βιβλιογραφία

- Example Spark 3.0.1 Data Transformations in Python, Sandeep Kattepogu,https://sandeepkattepogu.medium.com/python-spark-transformations-on-kafka-data-8a19b498b32c
- Single Node Spark/PySpark Cluster on Windows Subsystem for Linux (WSL2), Shafiqul Islam, https://medium.com/@aitmsi/single-node-spark-pyspark-cluster-on-windows-subsystem-for-linux-wsl2-22860888a98d
- Apache Kafka Quickstart,https://kafka.apache.org/quickstart

- MongoDB aggregation pipeline, https://www.mongodb.com/docs/manual/reference/operator/aggregation-pipeline/
- Spark Structured Streaming in general, https://spark.apache.org/docs/3.1.1/api/python/reference/pyspark.ss.html
- MongoDB-Spark connector, https://www.mongodb.com/docs/spark-connector/current/
- Spark-Kafka connection, https://spark.apache.org/docs/latest/structured-streaming-kafka-integration.html
- Mongodb-compass installation, https://www.mongodb.com/docs/compass/current/install/
- MongoDB installation guide on Ubuntu, https://www.mongodb.com/docs/manual/tutorial/install-mongodb-on-ubuntu/